

Integración de la IA en la evaluación de daños por desastres naturales

Javier Concha Gómez
Trabajo de Fin de Grado

TITULACIÓN

Grado en Ingeniería de Tecnologías y Servicios de Telecomunicación

ÁREA

Servicios basados en localización y espacio inteligente

TUTORA

Anna Muñoz Bolas

PROFESOR RESPONSABLE


Antoni Pérez Navarro

Índice



CONTEXTO

Justificación y riesgo climático



ESTADO DEL ARTE

IA y teledetección



OBJETIVOS

Metas del proyecto



DESARROLLO TÉCNICO

Metodología e implementación



DEMOSTRACIÓN

Visor interactivo




CONCLUSIONES

Resultados y futuro

Contexto y justificación

Alta exposición a desastres

España se sitúa en una posición crítica en Europa frente a fenómenos meteorológicos extremos.



Climate Risk Index 2025: Octavo país con más impacto acumulado.

Impacto reciente: DANA 2024 (237 fallecidos) e incendios forestales de 2025.

Necesidad: Información georreferenciada inmediata para la gestión de crisis y recuperación.

Motivación


Del dato bruto a la acción

Integrar conocimientos de SIG y geotelemática para automatizar el flujo de información en emergencias.

El objetivo es transformar imágenes aéreas masivas en inteligencia accionable para protección civil.

Escenario de Validación:

Erupción volcánica de La Palma (2021). Un entorno idóneo para medir la eficacia de detección de cambios drásticos.



Estado del arte

Evolución tecnológica


El procesamiento tradicional dependía del análisis humano manual, inviable ante el volumen de datos actual.

Deep Learning

Permite la automatización masiva.

Segmentación semántica

A diferencia de la detección de objetos, la segmentación clasifica **píxel a píxel**, permitiendo delimitar la silueta exacta.



Estado del arte

Evolución tecnológica

El procesamiento tradicional dependía del análisis humano manual, inviable ante el volumen de datos actual.


Deep Learning

Permite la automatización masiva.

Segmentación semántica

A diferencia de la detección de objetos, la segmentación clasifica **píxel a píxel**, permitiendo delimitar la silueta exacta.

Arquitectura U-Net: El estándar en segmentación biomédica y satelital por su capacidad de comprender contexto.



Soluciones




Defensa y militar

Proyecto SEDA:

Utilizado por el Ministerio de Defensa. Procesa datos radar y ópticos para identificar infraestructuras y buques.

Alta capacidad, pero propietario y restringido.



Ámbito civil

Open Source & GeoAI:

Trasladar capacidades militares al uso civil utilizando bibliotecas abiertas y datos de Copernicus.

Ejecutable en hardware convencional sin costes de licencia.

Objetivos

Desarrollar un flujo de trabajo automatizado para procesar áreas afectadas de manera desatendida.



1. Datos

Localización, descarga y tratamiento de ortofotos y cartografía vectorial abierta.



2. Modelo

Diseño y entrenamiento de red neuronal (CNN) ajustada al territorio.



3. Regularización

Conversión de detecciones de píxeles a polígonos geométricos limpios.



4. Validación

Comparativa con informes oficiales y visualización interactiva.

Metodología

Estrategia en cascada

Desarrollo secuencial donde la calidad del entrenamiento depende de la preparación de datos previa.



Python: Lenguaje vehicular.




Jupyter Notebooks: Documentación ejecutable.



GeoAI: Segmentación de huellas..



QGIS: Análisis y validación final.



Impacto



Eficiencia energética

El entrenamiento intensivo de IA tiene un alto coste en recursos hídricos y eléctricos.

Transfer Learning


En lugar de entrenar desde cero, ajustamos modelos pre-entrenados. Esto reduce drásticamente la huella de carbono y permite la ejecución en hardware local.

Implementación - Fase 1

Preparación de datos y Tiling

Las imágenes satelitales de alta resolución (20cm/px) son demasiado grandes para la memoria GPU.

- **Fragmentación:** Descomposición en teselas de 512x512 píxeles.
- **Solapamiento (50%):** Técnica crítica para garantizar que los edificios en los bordes se detecten completos en la tesela adyacente.



Implementación - Fase 2

Experimentación y selección de modelos

Comparativa de arquitecturas base (Encoders) para U-Net:

Métrica	U-Net + ResNet-34	U-Net + MobileNetV2	U-Net + EfficientNet B1
Train Loss	0.0384	0.0412	0.0321
Val Loss	0.0408	0.0423	0.0331
Val IoU	0.8573	0.8515	0.8773
Val F1	0.9137	0.9052	0.9271
Val Precision	0.9398	0.9135	0.9523
Val Recall	0.8989	0.9139	0.9130



ResNet-34

Equilibrio entre profundidad y conexiones residuales.



MobileNetV2

Optimizado para ligereza y velocidad.




EfficientNet-B1

Escalado compuesto de profundidad y resolución.

Modelo - ResNet-34

Aunque EfficientNet ofreció ligera superioridad, ResNet-34 fue seleccionado por su **balance óptimo** entre precisión y coste computacional.

85%
IoU (Intersection over Union)



91%
F1 Score

Alta capacidad para discernir edificios reales en condiciones de ceniza y sombras.

Implementación - Fase 3

Procesamiento y regularización

1. Máscara de probabilidad: Inferencia sobre ortofotos completas.

```
Analizando imagen base: orto_2021_clipped.tif...
-> Procesando cuadrante: tile_tl...
Input file format: GeoTIFF (.tif)
Processing 3744 windows...
387lit [01:18, 49.62it/s]
Using probability threshold: 0.3
Predicted classes: 2 classes, Background: 97.8%
Inference completed in 93.83 seconds
Saved prediction to ../data/processed/raster/temp_tiles_2021/tile_tl_pred.tif
-> Procesando cuadrante: tile_tr...
Input file format: GeoTIFF (.tif)
Processing 3744 windows...
387lit [01:16, 50.52it/s]
Using probability threshold: 0.3
Predicted classes: 2 classes, Background: 98.2%
Inference completed in 92.47 seconds
Saved prediction to ../data/processed/raster/temp_tiles_2021/tile_tr_pred.tif
-> Procesando cuadrante: tile_bl...
Input file format: GeoTIFF (.tif)
Processing 3744 windows...
387lit [01:17, 49.88it/s]
Using probability threshold: 0.3
Predicted classes: 2 classes, Background: 99.1%
Inference completed in 93.41 seconds
Saved prediction to ../data/processed/raster/temp_tiles_2021/tile_bl_pred.tif
-> Procesando cuadrante: tile_br...
Input file format: GeoTIFF (.tif)
Processing 3744 windows...
387lit [01:16, 50.30it/s]
Using probability threshold: 0.3
Predicted classes: 2 classes, Background: 98.6%
Inference completed in 92.85 seconds
Saved prediction to ../data/processed/raster/temp_tiles_2021/tile_br_pred.tif
Generando mosaico final: orto_2021_prediction.tif...
100 - done.
0...10...20...30...40...50...60...70...80...90...
-> Proceso finalizado con éxito. Segmentación disponible en ../data/geoai/results/orto_2021_prediction.tif
```

Implementación - Fase 3

Procesamiento y regularización


1. Máscara de probabilidad: Inferencia sobre ortofotos completas.
2. Vectorización: Conversión de píxeles a geometrías.
3. Regularización adaptativa: Simplificación de bordes para obtener contornos rectos y esquinas limpias.



Implementación - Fase 3

Procesamiento y regularización

1. Máscara de probabilidad: Inferencia sobre ortofotos completas.
2. Vectorización: Conversión de píxeles a geometrías.
3. Regularización adaptativa: Simplificación de bordes para obtener contornos rectos y esquinas limpias.
4. Filtrado: Eliminación de ruido ($< 15\text{m}^2$).



Visor interactivo - Swipe


Tecnología Leaflet con Swipe Tool

◀ Pre-desastre (2021) Post-desastre (2024) ▶

Efectos de la erupción en La Palma, 2021

Antes y después

Verificación de daños



☒ Edificios identificados en 2021

☒ Edificios identificados en 2024
☐ Edificios perdidos en el desastre



Visor interactivo - Swipe

Tecnología [Leaflet](#) con Swipe Tool

◀ Pre-desastre (2021) Post-desastre (2024) ▶

Visor interactivo - Pérdidas

Cálculo preliminar basado en la diferencia de detecciones:


5.273
Iniciales (2021)

-

3.056
Finales (2024)

=

2.217
Edificios Desaparecidos
(Entre capas)



Mapa generado destacando únicamente las estructuras eliminadas por la colada.

Visor interactivo - Validación


Comparativa con Copernicus

Validación espacial contrastando la IA con datos de análisis profesional.

Verde: Coincidencia.

Rojo: Discrepancia.

Resultado: Alta correspondencia con los expertos, reduciendo el tiempo de respuesta de días a horas.



Conclusiones

Viabilidad y precisión

La unión de Deep Learning y Open Data permite monitorizar desastres con precisión técnica sobresaliente.

El análisis espacial refinado ajustó la cifra final de impacto:

2.919 Edificios perdidos

2.988 Edificios presentes en el análisis de Copernicus



Validando la robustez del modelo y la regularización.

Trabajos futuros



Generalización

Validación en otros desastres
(Inundaciones, terremotos, etc.).



Tiempo real

Integración con satélites de
revisita diaria.



Plugin QGIS

Empaquetado como
complemento de escritorio para
uso fácil.



Cloud

Escalado mediante computación
en la nube.

MUCHAS GRACIAS



github.com/jcongom/TFG-disaster-building-footprint-extraction



jcongom.github.io/TFG-disaster-building-footprint-extraction